Entrega 5 – Relatório de qualidade dos dados

PSAE00320 – Técnicas de Pesquisa e Análise Econômica II · Turma 01 · 2026.2 · Equipe 01

Integrantes: Ana Beatriz Laurentino, Arthur Almeida e Gabriel Pinheiro · **Orientador:** Prof. Alessio · **Demandante:** CORECON-PB

Repositório: https://github.com/laurentinoanabia/TPAEII_equipe01 · **Notebook:** notebooks/03_obtencao_limpeza_tratamento.ipynb · **Data:** 27/10/2026

---

1. O que foi tratado e o que ainda não existe

> **Declaração de limite.** O questionário ainda **não foi aplicado**, então não há dados reais de respondentes. A única base real é o **glossário** (6 verbetes de rascunho). As regras de limpeza do questionário foram **testadas com uma base sintética com defeitos plantados** e também com um arquivo no formato real em uma cópia descartável do repositório. Os números do questionário neste relatório são do **teste**, não de pesquisa, e não devem ser citados como resultado.

Base	Origem	Situação	Saída
Glossário (F2)	Real	6 verbetes escritos pela equipe	data/processed/glossario_verbetes.csv, glossario_relacoes.csv, glossario_cobertura_questionario.csv
Questionário (F1)	Sintética (teste)	Aguardando a aplicação	outputs/sintetico_teste/ (nunca em data/processed/). Com o arquivo real, o mesmo notebook grava as tabelas agregadas em data/processed/

Resumo do relatório: 22 itens registrados (12 tratados, 5 verificados sem ocorrência, 2 pendências, 3 informativos).

2. Fontes, preservação e reprodutibilidade

- **Preservação:** os dados originais nunca são editados. O arquivo do glossário é lido como bytes e seu `sha256` (688481a2ba274403…) é conferido de novo no fim (teste de integridade). Ele é recuperável por qualquer commit do Git. As respostas reais do questionário ficam em `data/raw/`, bloqueada pelo `.gitignore`; para obtê-las de novo, basta exportar do formulário.
- **Reprodutibilidade:** o notebook executa do início ao fim sem intervenção manual. Duas execuções seguidas geraram os mesmos 15 arquivos, byte a byte (semente fixa 20261029).
- **Execução:** `jupyter nbconvert --to notebook --execute --inplace notebooks/03_obtencao_limpeza_tratamento.ipynb`

3. Contagens antes e depois de cada etapa

Base/tabela	Etapa	Linhas
glossario	bruto	6
glossario	após G2 (duplicidades)	6
glossario_relacoes	após G3 (explodir relacionados)	14
glossario_verbetes	após G4 (tabela final)	6
cobertura	pares item-verbete (antes da junção)	12
cobertura	pares item-verbete com verbete existente (depois da junção)	11
questionario	bruto	63
questionario	após Q1 (envios duplicados)	60
questionario	após Q2 (consentimento)	56
questionario	após Q6 (base limpa)	56
questionario_respostas	tabela final (1 linha por respondente)	56
questionario_multipla	tabela longa (1 linha por opção marcada)	320

Funil do questionário (teste): 63 linhas brutas − 3 envios duplicados − 4 sem consentimento = 56 respondentes. Junção glossário × itens do questionário: 12 pares item-verbete, 11 com correspondência.

4. Relatório de qualidade

4.1 Glossário e cobertura do questionário (dados reais)

Variável/base	Status	Problema encontrado	Decisão aplicada	Impacto/validação
glossario · textos	Sem ocorrência	Espaços extras ou formas Unicode diferentes nos campos de texto	Normalizar para NFC, colapsar espaços e aparar as pontas	0 células alteradas de 36; nenhuma linha removida
glossario · termo/slug	Sem ocorrência	Termos duplicados (mesmo identificador no site) ou sem nome	Nenhuma ação necessária	0 duplicados e 0 sem termo em 6 verbetes
glossario · relacionados	Sem ocorrência	Chaves sem correspondência: 'Veja também' apontando para verbete inexistente	Manter na tabela com destino_existe = False (o site oculta o link); corrigir na fonte	0 de 14 relações sem destino; 0 autorreferências
glossario · relacionados	Tratado	Relações assimétricas: A cita B, mas B não cita A	Manter como o autor escreveu (relação dirigida) e criar a coluna derivada `reciproca`; decidir na revisão se o link deve ser de mão dupla	2 de 14 relações sem retorno (14%): Reserva de emergência → Juros; Taxa Selic → Juros
glossario · fonte	Pendência	Campo `fonte` ausente: o verbete não diz de onde veio a definição	Manter ausente (não inventar fonte); marcar `tem_fonte = False` e tratar como pendência de revisão antes de publicar	6 de 6 verbetes sem fonte (100%). Afeta a rastreabilidade do glossário
glossario · exemplo/importa	Sem ocorrência	Campos opcionais vazios	Manter; sem imputação	exemplo ausente em 0, 'por que importa' ausente em 0 de 6
glossario · definicao	Sem ocorrência	Valores extremos de tamanho (definição muito curta ou muito longa)	Apenas sinalizar (limites 40 e 300 caracteres); não alterar o texto	0 curtas e 0 longas; mínimo 95, máximo 126 caracteres
glossario · tema	Informativo	Temas com poucos verbetes (filtro do site pouco útil)	Apenas registrar	3 temas: Planejamento financeiro (2); Crédito e dívidas (2); Economia geral (2)
cobertura questionário × glossário	Pendência	Chaves sem correspondência na junção: itens do questionário cujo verbete ainda não existe	Não criar verbete sem fonte para 'fechar' a conta; registrar como pendência de conteúdo (tarefa 12)	1 de 12 pares item-verbete sem correspondência; verbetes ausentes: Investimentos

4.2 Regras de limpeza do questionário (teste com dados sintéticos)

Variável/base	Status	Problema encontrado	Decisão aplicada	Impacto/validação
questionario · linhas	Tratado	Envios duplicados (linhas idênticas, inclusive o carimbo de data/hora)	Manter a primeira ocorrência	3 removidos; 63 → 60 linhas
questionario · consentimento	Tratado	Respostas de quem não aceitou participar (ou sem registro de aceite)	Excluir da análise; nenhuma informação delas é usada	4 removidas; 56 linhas restantes
questionario · colunas	Tratado	Colunas de identificação ou rastreio na exportação	Descartar antes de qualquer tabela (função `limpar_colunas` do script 02)	Descartadas: ['carimbo de data/hora', 'nome']
questionario · e3_termo_dificil	Tratado	Resposta aberta pode conter dado pessoal digitado pelo respondente	Remover das bases tratadas; revisão manual separada antes de qualquer uso	31 respostas abertas preenchidas não entram nas tabelas
questionario · categorias	Tratado	Variações de grafia do mesmo código (maiúsculas, acentos, espaços, hífen)	Normalizar com `norm_cod` (sem acento, minúsculo, '_' no lugar de espaço/hífen)	16 células de domínio fechado tiveram a grafia normalizada; sem perda de linhas
questionario · códigos inválidos	Tratado	Valores fora do domínio do livro de códigos	Transformar em ausente (NA); não adivinhar a intenção do respondente	6 valores invalidados: a3_idade (1), b1_reserva_def (1), b3_inflacao (1), b6_autoavaliacao (1), c1_orcamento (1), d2_fam_conversa (1)
questionario · c3/c4 × c2	Tratado	Cobertura e local da reserva preenchidos por quem diz não ter reserva	Anular c3 e c4 (a resposta a c2 prevalece, pois c3/c4 só valem com reserva)	6 respostas ajustadas; nenhuma linha removida
questionario · c5_dividas	Tratado	Opção excludente 'nenhuma' marcada junto com outras	Manter apenas as outras opções (contradição resolvida a favor da resposta positiva)	7 respostas ajustadas
questionario · d7_educ_recebida	Tratado	Opção excludente 'nunca' marcada junto com outras	Manter apenas as outras opções (contradição resolvida a favor da resposta positiva)	9 respostas ajustadas
questionario ·	Tratado	Mais de 3 temas marcados (o limite	Manter todos os marcados (a ordem de preferência é	4 respostas acima do limite; recomenda-se limitar no formulário

e1_temas_interesse		do formulário é 3)	desconhecida); sinalizar	
questionario · ausências	Informativo	Valores ausentes (em branco ou invalidados em Q4)	Não imputar. 'Não sei' e 'prefiro não responder' são categorias válidas; ausente fica fora do denominador de cada pergunta	b2_reserva_meses 7.1%; d3_fam_orcamento 5.4%; c1_orcamento 3.6%; d1_renda_familiar 3.6%; a3_idade 1.8%; b6_autoavaliacao 1.8%; b3_inflacao 1.8%; b1_reserva_def 1.8%; (c3/c4 ausentes por desenho: só valem com reserva)
questionario · escore	Tratado	Respondentes sem resposta válida em algum dos 4 itens pontuados	Ausente conta como não-acerto (mesma regra de 'não sei'); b2 e b6 não pontuam	2 de 56 respondentes afetados; escore médio 2.34
questionario · múltipla escolha	Informativo	Várias opções numa só célula separadas por ';' (viola 'uma variável por coluna')	Manter a forma ampla para o escore e criar a tabela longa `multipla` (uma opção por linha) para contagens	320 opções marcadas por 56 respondentes em 4 variáveis

5. Testes de integridade (42 de 42 OK)

Teste	Resultado	Detalhe
Glossário: chave (slug) única e não vazia	OK	
Questionário: nenhuma coluna de identificação sobrou	OK	
Domínio respeitado: a2_periodo	OK	
Domínio respeitado: a3_idade	OK	
Domínio respeitado: a4_ocupacao	OK	
Domínio respeitado: a5_renda_propria	OK	
Domínio respeitado: b1_reserva_def	OK	
Domínio respeitado: b2_reserva_meses	OK	
Domínio respeitado: b3_inflacao	OK	
Domínio respeitado: b4_juros_compostos	OK	
Domínio respeitado: b5_diversificacao	OK	
Domínio respeitado: b6_autoavaliacao	OK	
Domínio respeitado: c1_orcamento	OK	
Domínio respeitado: c2_tem_reserva	OK	
Domínio respeitado: c3_reserva_cobertura	OK	
Domínio respeitado: c6_poupa_regular	OK	
Domínio respeitado: d1_renda_familiar	OK	
Domínio respeitado: d2_fam_conversa	OK	
Domínio respeitado: d3_fam_orcamento	OK	
Domínio respeitado: d4_fam_reserva	OK	
Domínio respeitado: d5_fam_dividas	OK	
Domínio respeitado: d6_fam_conhecimento	OK	
Domínio respeitado: e2_usaria_glossario	OK	
Glossário: hash do arquivo original inalterado (preservação)	OK	
Glossário: contagem preservada (bruto = tratado)	OK	6 → 6
Glossário: 1 verbete por linha, slug único	OK	
Glossário: relações = soma de n_relacionados	OK	14 relações
Glossário: tipos esperados	OK	
Junção cobertura: contagem antes = linhas da tabela	OK	
Questionário: funil fecha (bruto − duplicados − sem consentimento = base limpa)	OK	63 − 3 − 4 = 56

Questionário: id_resposta único e sequencial	OK	
Questionário: escore entre 0 e 4	OK	
Questionário: nível definido para todos	OK	
Questionário: tabela longa só tem categorias válidas	OK	
Questionário: ninguém sem reserva tem c3/c4	OK	
Questionário: 'nenhuma' não aparece junto de outras dívidas	OK	
Teste sintético: 3 duplicatas plantadas foram removidas	OK	removidas 3
Teste sintético: 4 sem consentimento removidos	OK	removidos 4
Teste sintético: 6 códigos inválidos detectados	OK	detectados 6
Teste sintético: colunas de identificação descartadas	OK	['carimbo de data/hora', 'nome']
Frequências: 'base' de cada variável = respostas válidas	OK	
Frequências: nenhuma célula com n < 5 exposta	OK	

6. Limitações que permaneceram

1. **Sem dado real do questionário.** As regras foram provadas em dados sintéticos; falta executá-las na exportação real e conferir se o formulário exporta os códigos de `outputs/livro_de_codigos.csv`.
2. **Glossário pequeno e sem fontes:** 6 verbetes de rascunho, nenhum com campo `fonte`. Pendência de conteúdo antes de publicar.
3. **Verbete ausente:** "Investimentos", exigido pelo item b5 do questionário, ainda não existe. Não foi criado sem fonte para "fechar" a conta.
4. **Relações assimétricas** no "Veja também" (2 de 14); mantidas como o autor escreveu.
5. **Sem imputação:** ausentes e inválidos ficam como NA; "não sei" e "prefiro não responder" são categorias válidas.
6. **Privacidade:** respostas individuais, identificação e texto livre nunca entram em tabelas versionadas; células com menos de 5 respondentes aparecem como "<5".
7. **Limites do desenho da pesquisa:** amostra por conveniência, autodeclaração e relato do estudante sobre a família.